

## 7.4 ギブスサンプリングに 向けて

# ギブスサンプリングを考える前に

- ギブスサンプリング for 複数のパラメーターを持つモデル

## 例

- 患者97名。新薬投与51人→12人が改善、偽薬投与46人→5人が改善  
患者間の相互作用は薬の効果に影響しない（＝独立）
- コイン $j$ の表のバイアス $\theta_j$ を考える（ $j = 1, 2?$ ）  
 $N_j$ 回のコイン投げで、表が観測される数： $z_j$   
 $i$ 番目のコイン投げの結果： $y_{ji}$ （ $y=0$ で裏,  $y=1$ で表）  
表と裏の確率の式  $\cdots p(y|\theta) = \theta^y(1-\theta)^{(1-y)}$  ベルヌーイ分布

ベータ分布の共役事前分布

事前分布：ベータ関数  
尤度関数：ベルヌーイ分布  
事後分布：ベータ関数

- 今までとの違い…パラメータが複数存在・同時に動く  
パラメータそのものの動きを観測

## 2つのバイアスの事前分布・尤度・事後分布

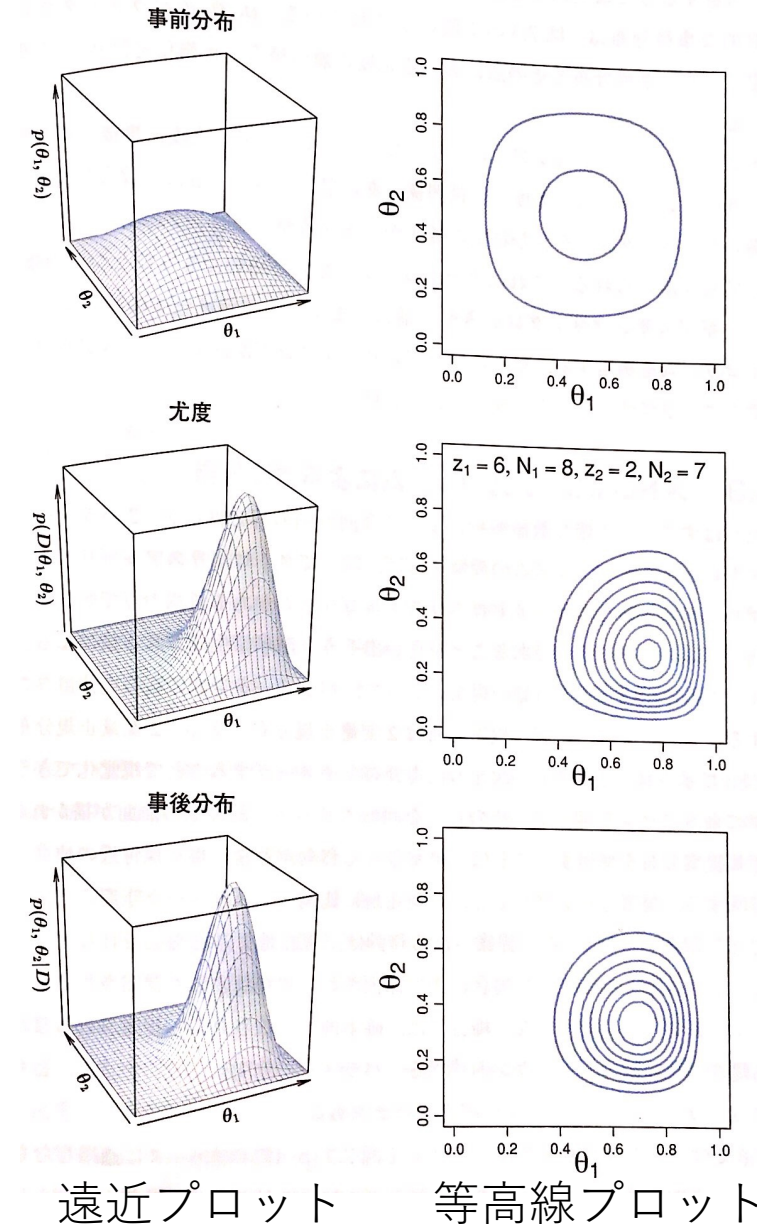
- 2個のコインに、バイアス  $\theta_1, \theta_2$  が想定
  - バイアスはパラメータ  $\theta$  の名前。0.5から逸脱する  $\theta$  の値「ではない」
- 前提：「パラメータ値の組み合わせにより事象が左右される」
  - $\theta_1, \theta_2$  の組み合わせに対する確信度： $p(\theta_1, \theta_2) \leftarrow \theta_1, \theta_2$  に支配
- 確信度…確率密度関数の形式をとる（＝尤度？）

周辺分布

- $\theta_1, \theta_2$  (の信念) が独立である  $\rightarrow p(\theta_1, \theta_2) = p(\theta_1)p(\theta_2)$ 
  - (独立の場合：計算は単純)
- データセット：  $D = \{z_1, N_1, z_2, N_2\}$  とする
- $p(D|\theta_1, \theta_2) = \prod_{y_{1i} \in D_1} p(y_{1i}|\theta_1, \theta_2) \prod_{y_{2i} \in D_2} p(y_{2i}|\theta_1, \theta_2)$   
 $= \theta_1^{z_1} (1 - \theta_1)^{(N_1 - z_1)} \theta_2^{z_2} (1 - \theta_2)^{(N_2 - z_2)} \pi r^2 \quad \leftarrow \text{尤度関数}$

# 正確に式の分布をすることによる事後分布

- ベータ関数：ベルヌーイ分布や二項分布の共役事前分布
  - パラメータは二つ： $a, b$
  - 平均は $a/(a+b)$
  - $a=b=1$ のとき一様分布
  - $a=b$ のとき $1/2$ を中心に対称
- 事後分布  $\propto$  尤度  $\times$  事前分布  
ベータ分布      ベルヌーイ分布      ベータ分布
- パラメータ  $\theta_1 \theta_2$  の事前分布  
…両方大体0.50？でも確信はない  
(丘がなだらかな)



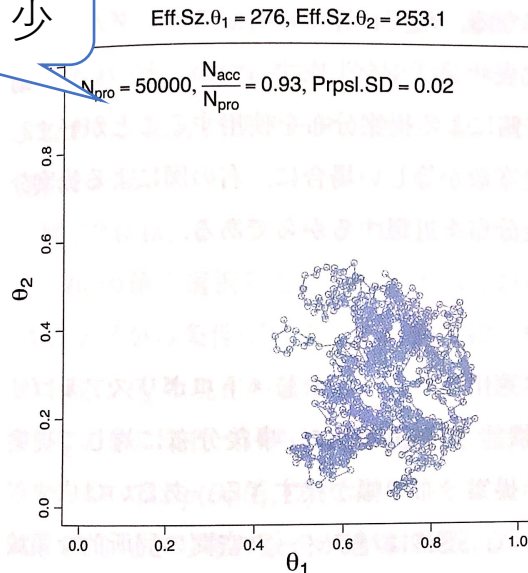
# メトロポリスアルゴリズムによる事後分布

- 今までとの違い…パラメータが複数存在・同時に動く  
パラメータそのものの動きを観測

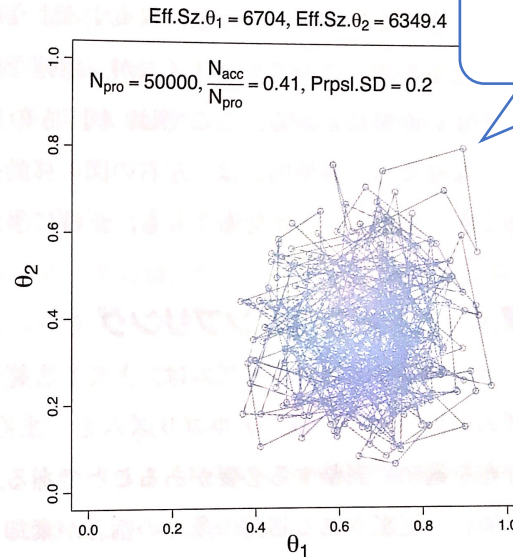
## メトロポリスの場合

- 現在地の尤度 < 次候補の尤度 → 必ず次候補に移動
- 次候補の尤度  $\leq$  現在地 → 確率で次候補に移動/停滞

移動幅小  
「停滞」少

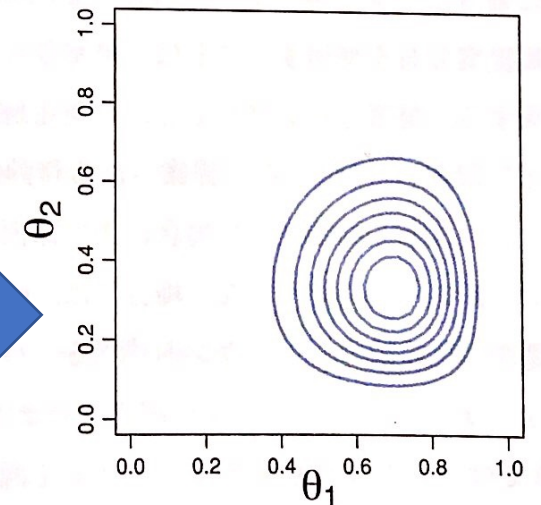


移動幅大  
「停滞」多



(同じステップ数なら)  
より効率的  
正確に事後分布近似

似てる！



# ギブスサンプリングによる事前分布

- メトロポリスアルゴリズムの問題
  - 事後分布に対して、移動先を決めるための尤度分布を調整させなきゃいけない
  - (尤度分布の幅が小さすぎor大きすぎ→停滞続き)
- ギブスサンプリング：メトロ同様ランダムウォーク
- 違い①：各ステップにおける、パラ決定の順番
  - メトロ…  $(\theta_1, \theta_2) \rightarrow (\theta_1, \theta_2) \rightarrow (\theta_1, \theta_2) \rightarrow (\theta_1, \theta_2)$
  - ギブス…  $\theta_1 \rightarrow \theta_2 \rightarrow \theta_1 \rightarrow \theta_2 \rightarrow \theta_1 \rightarrow \theta_2$
- 違い②：各ステップにおける、パラの移動様態
  - 次スライドにて説明

パラ数多くても、全パラに均等になるように順番こ



# 次ステップへの移動に関する、 メトロとギブスの差異



## メトロ

移動しない時もある

(移動距離 = 点線円の半径  
は既定)

- ① 候補地の選定
- ② 候補地の尤度計算
- ③ 移動の有無を決定  
< 繰り返し >

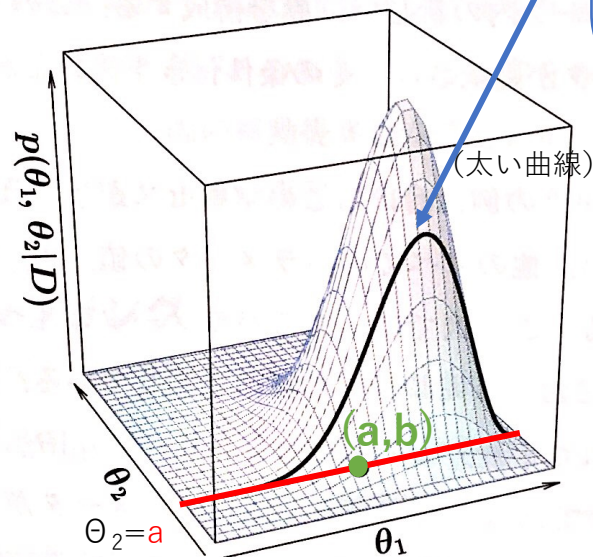
事後分布




## ギブス

毎回必ず移動

事後分布




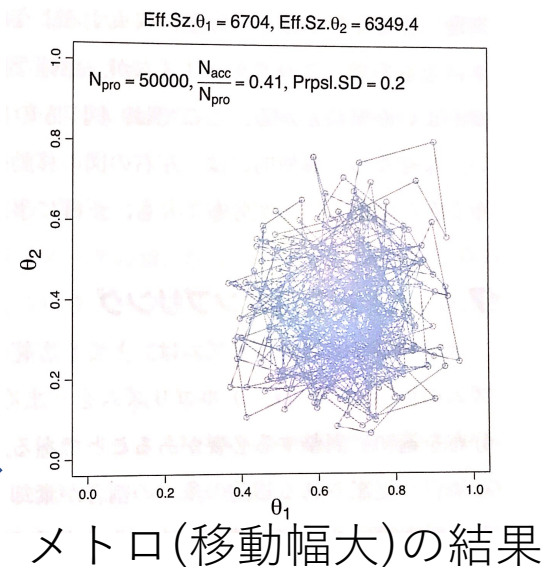
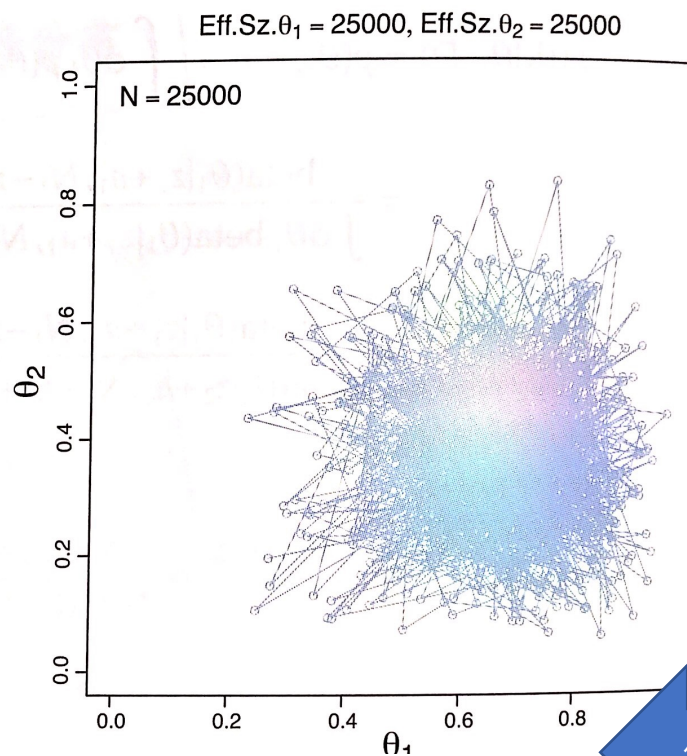



- ① 暫定のパラ:  $\theta_2 = a$
- ②  $\theta_2 = a$  の断面の **確率密度関数** から、確率にしたがって  $(a, b)$  を選定
- ③ 暫定のパラ:  $\theta_1 = b$
- ④ ② 同様、 $(c, b)$  を選定  
< 繰り返し >



# ギブスサンプリングの結果と ギブスとメトロの比較

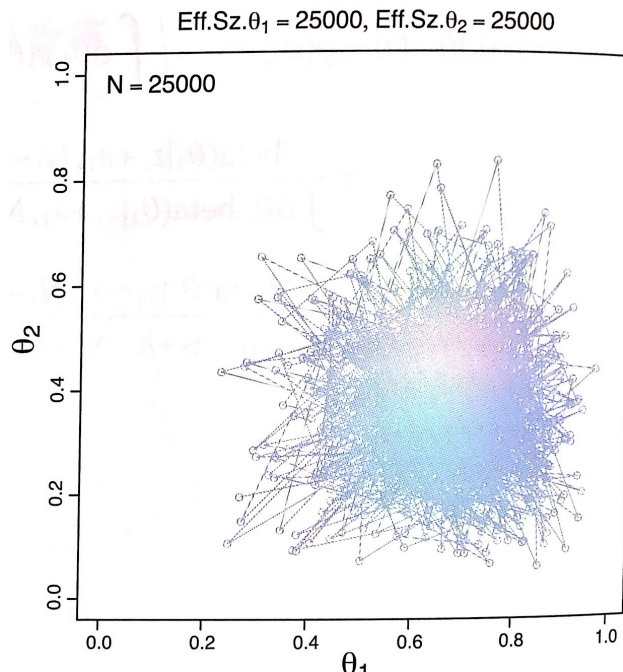
- ギブスサンプリングの結果
  - ↓ 左における2ステップを1ステップにしたのが右






# ギブスサンプリングの結果と ギブスとメトロの比較



余談：このように視覚化すると…  
・サンプリングの挙動がすぐにわかる  
・なぜサンプリングが機能するのかを理解する助けになる????



ギブスの結果



メトロ(移動幅大)の結果



- ・問題：同じステップ数で、どちらが有効な結果を得られるか？
- ・有効サイズ：ギブス > メトロ（今回はたまたま）

# ギブスサンプリングの長所・短所

## 長所

- 提案の棄却(停滞)が不要  
= 計算省略・同ステップ数でより充実したパラメータ策定が可能
- 事後分布・尤度分布の調整が不要  
(メトロポリスアルゴリズムの欠点を克服)

## 短所

- 一方のパラを固定した時に、他のパラの確率分布を生成する必要がある  
(大変なこと?)
- 相関の高いパラ同士だと計算に時間がかかる  
(今回は省略)